Tecnológico de Monterrey

2/Noviembre/2025

Proyecto Integrador (TC5035) Identificación de Gestos en el Lenguaje de Manos Mexicano

Avance 6. Conclusiones Clave

EQUIPO 51

CARLOS MIGUEL ARVIZU DURÁN - A01410682

YOHANNA CEBALLOS SALOMÓN - A01795115

RUBÉN DÍAZ GARCÍA - A01371849

PROFESOR ASESOR: DR. RAÚL VALENTE RAMÍREZ VELARDE

PROFESORA TITULAR: DRA. GRETTEL BARCELÓ ALONSO

PROFESOR TITULAR: DR. LUIS EDUARDO FALCÓN MORALES

PROFESORA ASISTENTE: MTRA. VERÓNICA SANDRA GUZMÁN DE VALLE

Contenido

Introducción 3
Análisis del Modelo 4
Análisis General 4
Resultados del modelo MLP 4
Criterios de decisión (Go/No-Go) propuestos: 6
Recomendaciones inmediatas (modelo/datos): 6
Resumen comparativo de modelos: 6
Rendimiento de modelo para producción 7
Margen de mejora 8
Recomendaciones clave 8
Accionables 9
Roles de stakeholders 9
Implementación 11
Recomendación 12
Plan propuesto 12
Bibliografía 13

Introducción

El presente proyecto integrador tiene como propósito desarrollar un sistema de reconocimiento automático de gestos dinámicos pertenecientes a la Lengua de Señas Mexicana (LSM) mediante el uso de técnicas de aprendizaje profundo y procesamiento de video. Para esta tarea, se selecciona un vocabulario de cuatro gestos específicos: "abrir", "tú", "avión" y "borrar".

Este esfuerzo busca sentar las bases para una herramienta tecnológica que contribuya a la inclusión social y comunicativa de las personas sordas, facilitando la traducción y comprensión de señas en tiempo real.

La investigación parte del desafío de reconocer gestos dinámicos (los que involucran movimiento y transición entre posturas), empleando la herramienta MediaPipe (MediaPipe Solutions guide, n.d.) para la extracción de keypoints de manos, brazos y rostro, realizar su extracción de características y posteriormente aplicar modelos de redes neuronales. Durante las etapas de experimentación se evaluaron distintas arquitecturas (GRU, CNN1D, BiLSTM y MLP).

Más allá del rendimiento cuantitativo, este proyecto también busca establecer una metodología reproducible que permita escalar el sistema mediante la recolección colaborativa de datos. La visión a mediano plazo consiste en liberar una aplicación que funcione no solo como traductor, sino también como plataforma de recopilación y retroalimentación que genere una base de datos más diversa y representativa de los distintos estilos de seña.

Análisis del Modelo

Análisis General

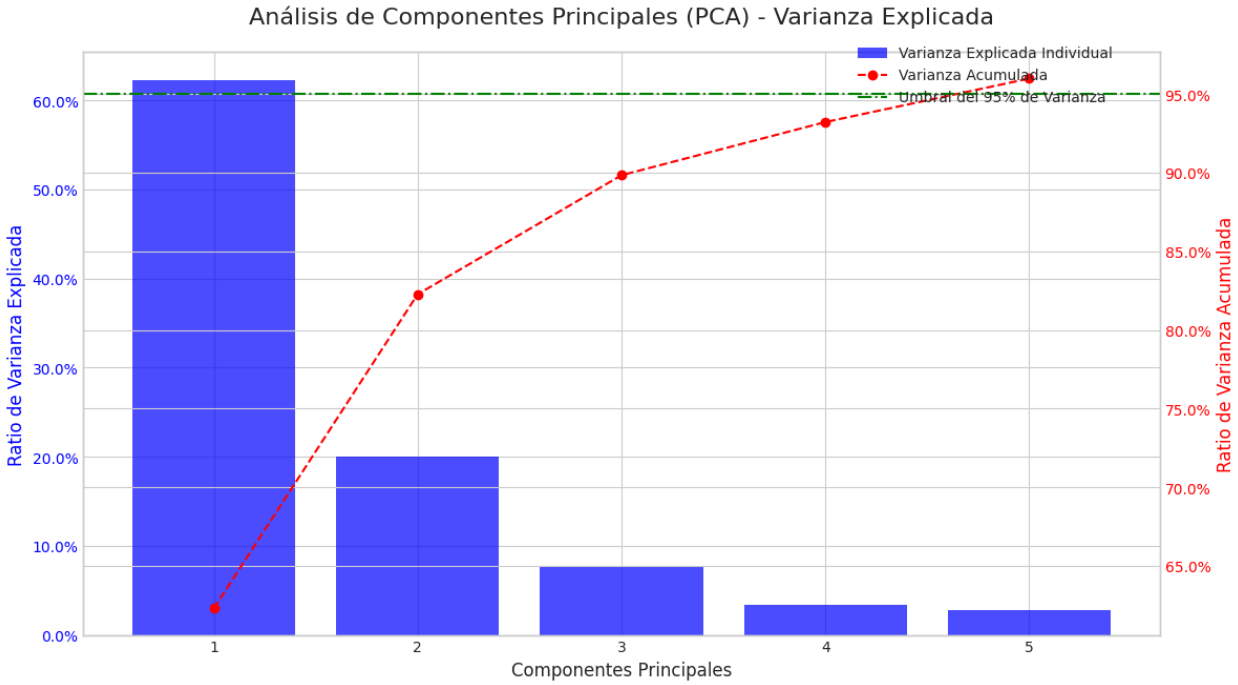
El modelo final seleccionado para la clasificación de gestos dinámicos de la Lengua de Señas Mexicana (LSM) corresponde al **Modelo 4 (MLP simple)**. El objetivo es reconocer cuatro gestos —abrir, tú, avión y borrar— a partir de secuencias de video procesadas con MediaPipe (keypoints).

Las métricas del MLP fueron las siguientes:

- Accuracy Test: 97%
- Accuracy Val: 81%
- Recall: 97%
- F1-Score: 97%

Nota de validez: Para evitar sobreestimación del desempeño, las métricas "finales" deben confirmarse con particiones por persona (*signer-independent*), es decir, sujetos distintos en *train/val/test*. Si las cifras anteriores no provienen de un *split* por persona, deben considerarse indicativas y no definitivas para producción.

Resultados del modelo MLP

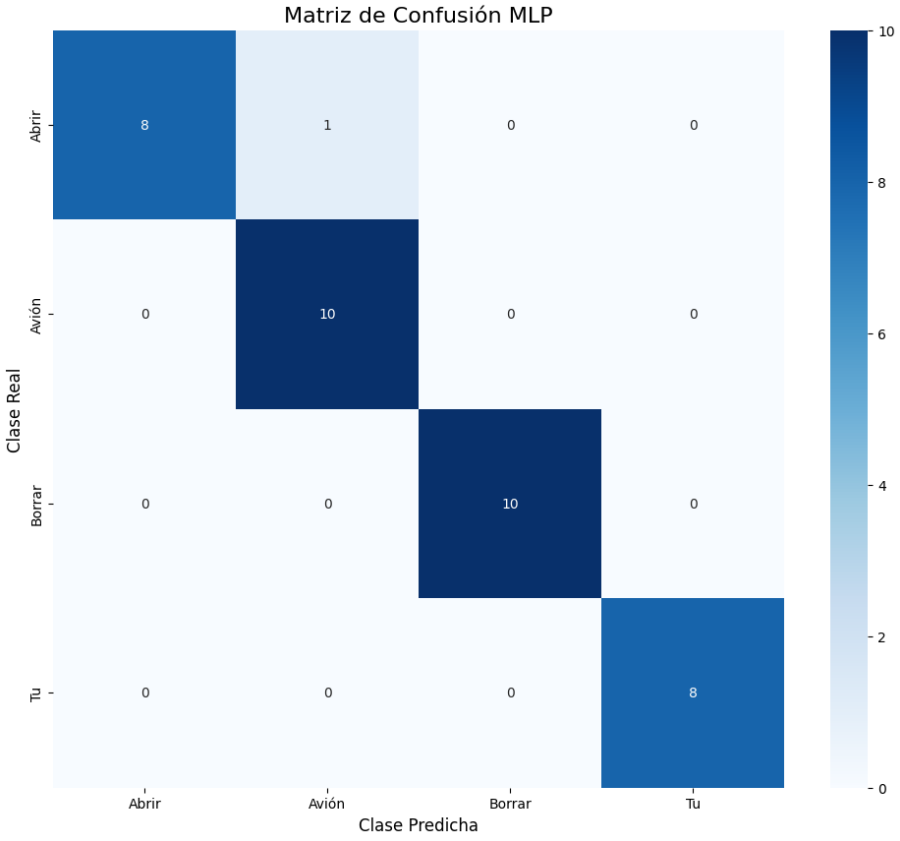


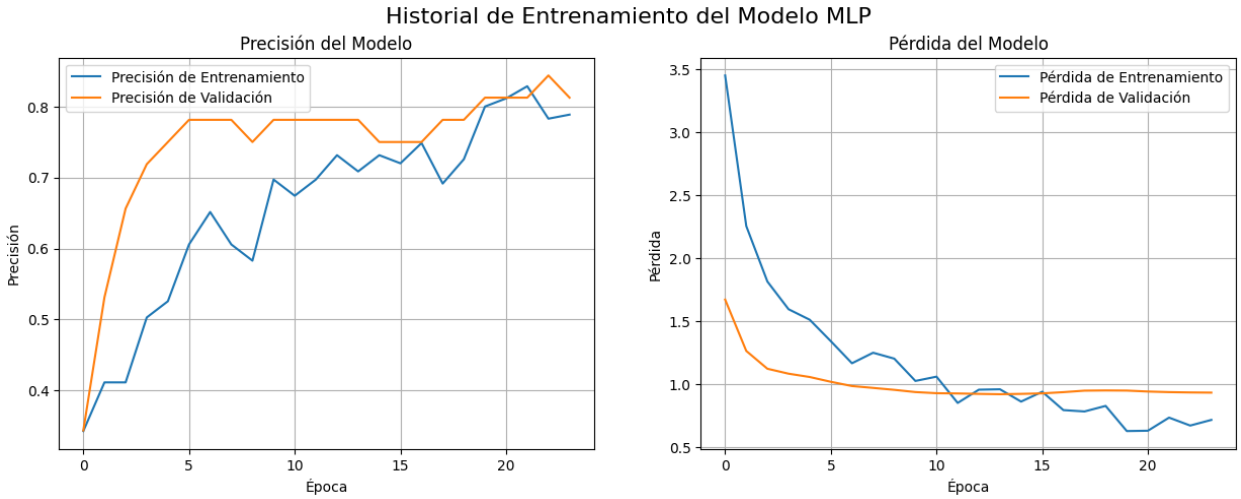
```
--- Reporte de Clasificación ---
              precision    recall  f1-score   support

       Abrir       1.00      0.89      0.94         9
       Avión       0.91      1.00      0.95        10
      Borrar       1.00      1.00      1.00        10
          Tu       1.00      1.00      1.00         8

    accuracy                           0.97        37
   macro avg       0.98      0.97      0.97        37
weighted avg       0.98      0.97      0.97        37

La precisión (accuracy) del modelo es: 0.97
El recall (weighted) del modelo es: 0.97
El F1-score (weighted) del modelo es: 0.97
```





Criterios de decisión (Go/No-Go) propuestos:

Criterio (signer-independent)	Go	Retocar y pilotear	Retroceder
Macro-F1	≥ 0.90	0.85–0.89	< 0.85
Latencia p95 (captura→pred)	≤ 40 ms	41–80 ms	> 80 ms
Varianza de F1 entre personas	≤ 4 p.p.	5–8 p.p.	> 8 p.p.

Recomendaciones inmediatas (modelo/datos):

- Repetir evaluación con Group/StratifiedGroup Split por signer_id.
- Reportar F1 por clase y matriz de confusión (identificar pares confusos).
- Ejecutar análisis de sensibilidad del pipeline: padding (p90/p95/p99) y PCA (90–99% varianza) para optimizar la relación F1 ↔ latencia.

Estas métricas posicionan al MLP como la mejor alternativa entre los modelos evaluados (GRU, CNN1D, BiLSTM), equilibrando rendimiento y eficiencia computacional. No obstante, es fundamental puntualizar que el conjunto de datos empleado en esta versión proviene exclusivamente de la base MX-ITESO-100 (Martínez-Sánchez et al., n.d.) y presenta un alto grado de similitud entre videos, lo que puede explicar parte del alto rendimiento y, a la vez, limitar la generalización del modelo a contextos más variados.

Resumen comparativo de modelos:

ID	Modelo	Accuracy Test	Accuracy Val	Recall	F1-Score	Tiempo de entrenamiento s	Sobreajuste
4	MLP	97	81	97	97	5.5	No
2	GRU	95	71	95	95	12.5	Sí
3	CNN1D	92	81	92	92	15.7	Sí (alto)
7	BiLSTM	89	75	89	90	21.3	Sí
9	CNN1D+MLP	87.5(en subconjunto)	-	-	-	21.2	Sí
10	BiLSTM+MLP	75(en subconjunto)	-	-	-	26.8	Sí
8	GRU+MLP	62(en subconjunto)	-	-	-	18	Sí
11	GRU+BiLSTM	50(en subconjunto)	-	-	-	33.8	Sí

En conclusión, el rendimiento del MLP es suficiente para una prueba de concepto y un entorno de validación controlado; sin embargo, se recomienda ampliar la diversidad del dataset antes de un despliegue definitivo para mitigar posible sesgo de generalización.

Rendimiento de modelo para producción

¿El rendimiento del modelo es lo suficientemente bueno para su implementación en producción?

En el estado actual del desarrollo de este modelo no está listo para implementación en producción como un traductor, como se plantea desde la fase inicial del proyecto se plantea una iteración intermedia en la búsqueda de un modelo que sea capaz de traducir completamente el Lenguaje de Señas Mexicano a español. Como modelo para producción se plantea la liberación del modelo como parte de una aplicación que ayude en la generación de una base de datos más robusta, es decir una aplicación que permita a cualquier persona, grabar etiquetar y testear el modelo en producción y por último subirlo a la base de datos con los permisos y avisos de privacidad necesarios para que puedan enriquecer la base de datos y el modelo sea capaz de poderse reentrenar y ajustar con más datos.

Como se mencionó anteriormente se obtuvo una base de datos de las señas —abrir, tú, avión y borrar— que forman parte de las señas más utilizadas para comunicarse cotidianamente. Aunque se tuvieron muy buenos resultados en las pruebas con los datasets controlados, se obtuvieron resultados muy variables al introducir datos ajenos al dataset, si bien se tienen una cantidad considerable de datos para los entrenamientos, la variabilidad de estos datos no es tanta siendo muchos videos muy similares entre ellos lo que previene al algoritmo de ajustarse a las características más importantes que se pueden obtener cuando se tienen una gran cantidad de datos más diversos. De cualquier manera, se lograron buenos resultados dentro de las limitaciones del dataset.

Margen de mejora

¿Existe margen para mejorar aún más el rendimiento?

Sin duda hay mucho margen para aumentar el rendimiento de los modelos generados, principalmente del lado de la cantidad y la diversidad de los datos de entrenamiento lo cual creemos mejorará notablemente el desempeño de nuestros modelos, incluso llegando a modificar las puntuaciones en las distintas métricas en los modelos, ocasionando que el orden se altere y modelos que inicialmente no dieron buenos resultados puedan obtener una cantidad de datos que les permitan identificar patrones más complejos mejorando notablemente en comparación de los modelos más sencillos que fueron los que mejores resultados obtuvieron. Lo anterior sustentado en cómo fueron mejorando algunos modelos con las semanas, pues cada semana añadimos datos nuevos a la base de datos para reentrenar a los modelos y volverlos a evaluar.

Recomendaciones clave

¿Cuáles serían las recomendaciones clave para poder implementar la solución?

1. Generar la aplicación para recopilación de datos y nutrir la base para poder diversificar la información.
2. Reentrenar los modelos con la base de datos más diversa para evaluarlos nuevamente y descubrir si los modelos fueron capaces de diferenciar nuevas características.
3. Repetir evaluación con Group/StratifiedGroup Split por signer_id, lo cual permitiría que se tengan datos de las diversas fuentes en todos los subconjuntos de datos (validación, entrenamiento y prueba) permitiendo que entren en entrenamiento y evaluación y evitar que los resultados queden sesgados.
4. Reportar F1 por clase y matriz de confusión (identificar pares confusos) y trabajar en las deficiencias del modelo.
5. Ejecutar análisis de sensibilidad del pipeline: padding (p90/p95/p99) y PCA (90–99% varianza) para optimizar la relación F1 ↔ latencia.

Accionables

Roles de stakeholders

De acuerdo con Miller (2022), los proyectos de inteligencia artificial requieren una definición clara de los roles de las partes interesadas para asegurar una implementación ética, sostenible y funcional.

El autor identifica seis roles fundamentales que deben interactuar de manera coordinada durante todo el ciclo de vida del proyecto:

- **Client**: persona u organización que encarga o financia el sistema de IA, define los objetivos estratégicos y evalúa el valor del resultado.
- **Decision Maker**: individuo o comité que aprueba y supervisa decisiones críticas, como la asignación de recursos, la selección del modelo o las políticas de uso.
- **Designer**: equipo científico y de investigación encargado de diseñar, entrenar y validar los modelos de IA.
- **Developer**: profesionales de ingeniería o software que implementan, integran y despliegan las soluciones técnicas derivadas del diseño del modelo.
- **Operator**: responsables de mantener, monitorear y operar el sistema una vez en producción, asegurando su desempeño y corrigiendo incidencias.
- **Reference / Representative (User)**: usuarios o comunidades que interactúan con el sistema y aportan retroalimentación o validación social del modelo.

Con base en este marco, las tareas accionables del proyecto de reconocimiento de gestos dinámicos de la Lengua de Señas Mexicana (LSM) se asignan de la siguiente forma:

Tarea / Procedimiento	Descripción / Objetivo	Stakeholder Responsable	Rol según Miller (2022)
Curación y expansión de datos	Ampliar la base de datos con videos de mayor diversidad de usuarios, cámaras, fondos y condiciones lumínicas.	Equipo de Ciencia de Datos	Designer / Developer
Validación cruzada y ajuste de hiperparámetros	Refinar la arquitectura y parámetros del MLP mediante experimentación sistemática y controlada.	Equipo de Modelado y Entrenamiento	Designer
Documentación del pipeline de preprocesamiento	Estandarizar la extracción de keypoints con MediaPipe y asegurar la reproducibilidad del proceso.	Equipo de Datos / Ingeniería	Developer / Operator
Contenerización del modelo	Empaquetar el modelo MLP y sus dependencias en un contenedor Docker para despliegue reproducible.	Ingeniería / DevOps	Developer / Operator
Desarrollo del endpoint de inferencia	Implementar API REST para recibir secuencias procesadas y devolver predicciones de gesto.	Equipo de Backend	Developer
Evaluación funcional y de desempeño	Probar latencia, precisión y estabilidad del modelo en escenarios reales y bajo carga.	Equipo de QA / Ciencia de Datos	Operator / Reference
Monitoreo y reentrenamiento programado	Implementar métricas de desempeño, alertas y plan de retraining mensual ante data drift.	Equipo de Ciencia de Datos / Operaciones	Operator / Decision Maker
Comunicación de resultados y retroalimentación	Reportar hallazgos a las partes interesadas institucionales y comunidades LSM para validar la utilidad social.	Dirección académica y stakeholders externos	Client / Representative

Este esquema de roles permite asegurar una gobernanza integral del sistema de IA, donde cada actor asume responsabilidades precisas.

La inclusión del rol Representative/User (la comunidad LSM) garantiza que las decisiones técnicas conserven pertinencia social y lingüística, fomentando la inclusión y el impacto positivo del proyecto.

Implementación

Se evaluaron AWS (SageMaker), Azure (Azure ML), IBM Watson Studio y Google Cloud Platform (Vertex AI + Cloud Run). Los criterios incluyeron facilidad de uso, escalabilidad, costos, servicios nativos de MLOps y compatibilidad con el stack.

Proveedor	Ventajas Principales	Consideraciones
AWS (Sage Maker)	• Ecosistema maduro. • Pipelines y endpoints administrados. • Integración IAM.	• Curva de aprendizaje mayor. • Costos pueden escalar.
Azure (Azure ML)	• Integración Microsoft. • Diseñador visual. • Buen CI/CD con Azure DevOps.	• Costeo menos claro. • Documentación heterogénea.
IBM (Watson Studio)	• UI sencilla. • AutoML.	• Menor adopción para personalización avanzada.
GCP (Vertex AI + Cloud Run)	• Flujo unificado de MLOps. • Serverless. • Autoscaling a 0. • Buena relación costo/operación.	• Requiere configuración inicial de permisos IAM.

En el caso de AWS SageMaker, su configuración inicial es compleja y los costos pueden incrementarse rápidamente, lo que lo hace más apropiado para entornos corporativos de gran escala que para proyectos académicos o de investigación aplicada.

Por su parte, Azure Machine Learning tiene una estructura de precios es menos transparente y ofrece menor flexibilidad para configuraciones avanzadas, lo que puede representar una limitante técnica en proyectos que demandan personalización.

IBM Watson Studio tiene una limitada compatibilidad con frameworks de código abierto y su menor presencia en proyectos de investigación avanzada reducen su idoneidad para sistemas personalizados como el modelo MLP utilizado en este caso.

Finalmente, Google Cloud Platform (GCP), a través de Vertex AI y Cloud Run, combina de manera equilibrada la facilidad de uso con una infraestructura flexible y de bajo costo. Permite entrenar modelos directamente desde notebooks administrados, automatizar su despliegue mediante pipelines reproducibles y exponerlos como servicios serverless, lo que elimina la necesidad de mantener servidores activos cuando no hay peticiones. Además, su compatibilidad nativa con frameworks como Keras, TensorFlow y PyTorch

favorece la continuidad del trabajo ya realizado en el entorno local y reduce el esfuerzo de adaptación.

Recomendación

Por las razones anteriores, la recomendación es la siguiente: **Google Cloud Platform** con **Vertex AI** (registro/versionado de modelos) y **Cloud Run** (servicio de inferencia en contenedor serverless). La elección se fundamenta en simplicidad operativa, pago por uso, escalabilidad automática y compatibilidad con Python/Keras.

Plan propuesto

- Fase 1 (training/validación en Vertex AI Notebooks)
- Fase 2 (deploy de API en Cloud Run)
- Fase 3 (monitoreo y retraining con Vertex Pipelines + Cloud Scheduler).

Bibliografía

1. Amazon Web Services. (s.f.). Amazon SageMaker – Build, train, and deploy machine learning models. Recuperado de https://aws.amazon.com
2. Google Cloud. (s.f.). Vertex AI – Unified platform for ML development and deployment. Recuperado de https://cloud.google.com
3. IBM. (s.f.). IBM Watson Studio – Build and scale AI models. Recuperado de https://www.ibm.com/mx-es/watson
4. MediaPipe Solutions guide. (n.d.). Google AI for Developers. https://ai.google.dev/edge/mediapipe/solutions/guide
5. Microsoft Azure. (s.f.). Azure Machine Learning – Accelerate the end-to-end machine learning lifecycle. Recuperado de https://azure.microsoft.com
6. Martínez-Sánchez, J., Torres, L., & Ramírez, J. (n.d.). MX-ITESO-100: Dataset de gestos de la Lengua de Señas Mexicana (LSM) [Base de datos]. Instituto Tecnológico y de Estudios Superiores de Occidente (ITESO).
7. Miller, G. (2022). Stakeholder roles in artificial intelligence projects. Project Leadership and Society, 3, 100068. https://doi.org/10.1016/j.plas.2022.100068