Tecnológico de Monterrey

9/Noviembre/2025

Proyecto Integrador (TC5035) Identificación de Gestos en el Lenguaje de Manos Mexicano

Avance 7. Resumen Ejecutivo

EQUIPO 51

CARLOS MIGUEL ARVIZU DURÁN - A01410682

YOHANNA CEBALLOS SALOMÓN - A01795115

RUBÉN DÍAZ GARCÍA - A01371849

PROFESOR ASESOR: DR. RAÚL VALENTE RAMÍREZ VELARDE

PROFESORA TITULAR: DRA. GRETTEL BARCELÓ ALONSO

PROFESOR TITULAR: DR. LUIS EDUARDO FALCÓN MORALES

PROFESORA ASISTENTE: MTRA. VERÓNICA SANDRA GUZMÁN DE VALLE

Contenido

Síntesis del problema 3
Formulación del problema 3
Contexto 3
Hallazgos más importantes del análisis exploratorio de datos 4
Modelos generados y razones de la elección del modelo final 5
Modelos 5
Metodología de comparación 5
Modelos ordenados por Accuracy (Métrica principal): 5
Selección de modelo 6
Recomendaciones clave para implementar la solución 8
Análisis Costo - Beneficio 8
Supuestos Generales 8
Costos por Fase CRISP-ML 9
Beneficios 12
Riesgos y desafíos de la solución 13
Riesgos relacionados con los datos 13
Riesgos de Ataques 13
Riesgos de Prueba y Confianza 14
Riesgos de Cumplimiento 14
Bibliografía 15

Síntesis del problema

El proyecto busca desarrollar un sistema de reconocimiento automático del LSM utilizando visión por computadora y modelos de aprendizaje supervisado. Su valor está en reducir barreras de comunicación entre personas sordas y oyentes, así como apoyar en educación, accesibilidad digital y servicios públicos.

Además, un traductor de señas a texto o voz puede integrarse en entornos como consultas médicas, trámites gubernamentales, plataformas de educación en línea y dispositivos inteligentes.

Formulación del problema

¿Qué se intenta resolver?

El problema central es que las personas sordas en México carecen de suficientes herramientas tecnológicas que automaticen la interpretación de la Lengua de Señas Mexicana. Actualmente, la mayoría de los sistemas trabajan con otras lenguas de señas (ej. ASL) y no consideran la gramática, morfología ni variaciones propias del LSM.

Este vacío tecnológico genera una brecha en la comunicación diaria y limita la inclusión social y laboral.

Contexto

¿Por qué es importante resolver este problema?

La comunidad sorda mexicana depende del LSM como lengua natural, con estructura gramatical propia distinta al español oral.

Tecnologías recientes como MediaPipe Hands permiten la captura en tiempo real de hasta 21 puntos clave de la mano, facilitando el modelado preciso de gestos.

Resolver este problema es importante porque contribuiría a la inclusión social y educativa, reduciría la dependencia de intérpretes humanos en situaciones críticas y sentaría bases para aplicaciones de traducción más robustas.

Hallazgos más importantes del análisis exploratorio de datos

El Análisis Exploratorio de Datos (EDA) fue una etapa crítica que reveló un desafío fundamental en el conjunto de datos base, MX-ITESO-100. (Martínez-Sánchez, Torres & Ramírez, n.d.)

Se utilizaron del dataset las palabras “Abrir”, “Avión”, “Borrar” y “Tú”.

Se identificó que este dataset, si bien es un valioso punto de partida, presenta un volumen de muestras limitado para la robustez deseada del proyecto. Más importante aún, se detectó una baja variabilidad en los registros existentes.

Esta homogeneidad se manifiesta principalmente en:

- Un número reducido de firmantes (las personas que realizan las señas).
- Condiciones de grabación muy controladas y consistentes (por ejemplo, iluminación uniforme, fondos similares y ángulos de cámara fijos).

Un dataset con estas características puede limitar la capacidad de un modelo para generalizar su aprendizaje a nuevos usuarios o a entornos del mundo real, que por naturaleza son mucho más variables.

Para mitigar esta limitación y enriquecer el material de entrenamiento, el equipo tomó la decisión estratégica de generar y añadir nuevos videos. Esta acción fue crucial para incrementar la diversidad y el número total de muestras.

A pesar de este aumento de datos, la influencia de la base original sigue siendo un factor a considerar. Por lo tanto, si bien los modelos desarrollados demuestran un alto rendimiento (como se detalla en la siguiente sección), sus resultados deben ser contextualizados. El rendimiento actual refleja un éxito en un entorno con variabilidad que, aunque mejorada por el equipo, sigue siendo controlada.

Este hallazgo subraya la importancia de la recopilación continua de datos como una recomendación clave para la siguiente fase del proyecto, permitiendo así mejorar la generalización y robustez del sistema en el futuro.

Por último se valida la viabilidad técnica de trabajar con Mediapipe para extraer las características de los datos e iniciar con el entrenamiento. (Mediapipe, n.d.)

Modelos generados y razones de la elección del modelo final

Modelos

Se generaron 8 modelos distintos:

- GRU (Gated Recurrent Unit)
- CNN1D (Convolución Unidimensional)
- MLP (Multilayer Perceptron)
- BiLSTM (Bidirectional Long Short-Term Memory)
- Se unen el 2 y el 4 - GRU + MLP.
- Se unen el 3 y el 4 - CNN1D + MLP.
- Se unen el 7 y el 4 - BiLSTM + MLP.
- Se unen el 7 y el 2 – BiLSTM + GRU.

Metodología de comparación

Los 8 modelos se entrenan bajo estas condiciones:

- Conjunto de entrenamiento y prueba idéntico (X_train, X_test).
- Objetivo Accuracy.
- Se utiliza el mismo pipeline y el label encoder para estandarizar, previamente obtenidos de este mismo ipynb en el preprocesamiento.
- Se selecciona Accuracy debido a que nuestro objetivo de clasificación no tiene ningún peso distinto entre las clases que se clasifican, siendo todas iguales en la evaluación.

Nota: Se optimizan los parámetros de todos los modelos obteniendo el mejor resultado posible. El tamaño del Batch y epoch obtuvo los mismos resultados.

Modelos ordenados por Accuracy (Métrica principal):

ID	Modelo	Accuracy Test	Accuracy Val	Recall	F1-Score	Tiempo de entrenamiento s	Sobreajuste
4	MLP	97	81	97	97	5.5	No
2	GRU	95	71	95	95	12.5	Sí
3	CNN1D	92	81	92	92	15.7	Sí (alto)
7	BiLSTM	89	75	89	90	21.3	Sí
9	CNN1D+MLP	87.5(en subconjunto)	-	-	-	21.2	Sí
10	BiLSTM+MLP	75(en subconjunto)	-	-	-	26.8	Sí
8	GRU+MLP	62(en subconjunto)	-	-	-	18	Sí
11	GRU+BiLSTM	50(en subconjunto)	-	-	-	33.8	Sí

Selección de modelo

Modelo 4 (MLP)

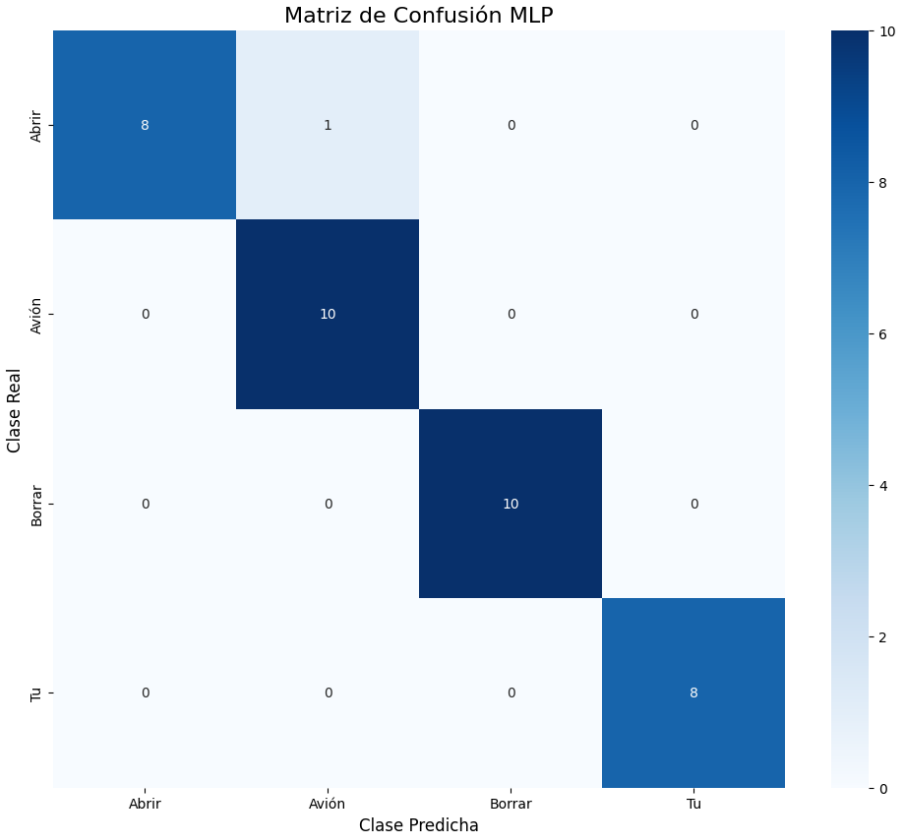
El Perceptrón Multicapa (MLP) destaca significativamente sobre las demás arquitecturas:

- Rendimiento Superior: Obtuvo las métricas más altas en todas las categorías clave, con un impresionante 97% tanto en Accuracy Test como en F1-Score. Esto indica que es el modelo más preciso y el que mejor equilibra la precisión y la sensibilidad (recall).
- Eficiencia: Es, por mucho, el modelo más rápido de entrenar, con un tiempo de solo 5.5 segundos. Esto es más del doble de rápido que el siguiente modelo (GRU) y casi cuatro veces más rápido que el BiLSTM.
- Robustez (Sin Sobreajuste): Este es su punto más fuerte. Es el único modelo en la tabla que no presentó sobreajuste ("No"). Logró generalizar correctamente lo aprendido en los datos de entrenamiento a los datos de prueba, lo cual es fundamental para un modelo confiable.

Matriz de Confusión y Reporte de Clasificación

La matriz de confusión demuestra un rendimiento excelente por parte del modelo MLP. Se observa una fuerte diagonal (con valores 8, 10, 10, 8), indicando que la gran mayoría de las predicciones (36 de 37) fueron correctas. De hecho, el modelo clasificó perfectamente las señas "Avión", "Borrar" y "Tu" sin cometer un solo error. El único fallo fue una leve confusión, donde una instancia real de "Abrir" fue clasificada erróneamente como "Avión", resultando en un modelo altamente preciso y robusto.

El reporte de clasificación confirma el buen rendimiento del modelo MLP con un 97% de accuracy general. Las métricas son buenas, salvo por una mínima confusión en la clase "Abrir". Aunque estos resultados validan el modelo, es realista considerar que este alto rendimiento está influenciado por la baja variabilidad del dataset. El modelo es experto en los datos de entrenamiento, pero presenta un riesgo de generalización ante nuevos firmantes, lo cual es el siguiente paso a robustecer.




```
--- Reporte de Clasificación ---
              precision    recall  f1-score   support

       Abrir       1.00      0.89      0.94         9
       Avión       0.91      1.00      0.95        10
      Borrar       1.00      1.00      1.00        10
          Tu       1.00      1.00      1.00         8

    accuracy                           0.97        37
   macro avg       0.98      0.97      0.97        37
weighted avg       0.98      0.97      0.97        37

La precisión (accuracy) del modelo es: 0.97
El recall (weighted) del modelo es: 0.97
El F1-score (weighted) del modelo es: 0.97
```

Recomendaciones clave para implementar la solución

- Generar la aplicación para recopilación de datos y nutrir la base para poder diversificar la información.
- Reentrenar los modelos con la base de datos más diversa para evaluarlos nuevamente y descubrir si los modelos fueron capaces de diferenciar nuevas características.
- Repetir evaluación con Group/StratifiedGroup Split por signer_id, lo cual permitiría que se tengan datos de las diversas fuentes en todos los subconjuntos de datos (validación, entrenamiento y prueba) permitiendo que entren en entrenamiento y evaluación y evitar que los resultados queden sesgados.
- Reportar F1 por clase y matriz de confusión (identificar pares confusos) y trabajar en las deficiencias del modelo.
- Ejecutar análisis de sensibilidad del pipeline: padding (p90/p95/p99) y PCA (90–99% varianza) para optimizar la relación F1 ↔ latencia.

Análisis Costo - Beneficio

Las cifras aquí presentadas no corresponden a gastos ejecutados, sino a supuestos racionales y transparentes, construidos para comunicar a las partes interesadas el esfuerzo real involucrado, dimensionar el posible costo de una futura implementación en producción y evaluar si los beneficios potenciales justifican la continuidad y escalamiento del proyecto.

Las cifras se sustentan en supuestos racionales y en tarifas publicadas de Google Cloud Platform (GCP) para la región de México (northamerica-south1, Querétaro).

Supuestos Generales

- Equipo de trabajo: 3 integrantes.
- Duración total: 9 semanas (~270 horas de trabajo conjunto).
- Valor estimado de hora técnica: $150 MXN.
- Costo total teórico de desarrollo: $40,500 MXN.
- Todo el software empleado fue de código abierto y gratuito.

Costos por Fase CRISP-ML

1. **Entendimiento del negocio y de los datos (10% del tiempo) - $4,050 MXN**

En esta etapa se definió el problema central: reconocimiento automático de cuatro gestos dinámicos en LSM (abrir, tú, avión, borrar) como prueba de concepto inicial. Se revisó literatura relacionada, se consideró la relevancia social del proyecto para comunidades sordas y se establecieron métricas principales.

Actividades:

- Revisión de antecedentes
- Análisis de requerimientos académicos
- Alineación con el equipo y los investigadores

2. **Preparación de los datos (25% del tiempo) - $10,125 MXN**

Se trabajó con el conjunto de datos estructurado MX-ITESO-100, organizando los videos por gesto y aplicando extracción de keypoints con MediaPipe. Aunque el conjunto de datos original tenía estructura, fue necesario validar la calidad de los videos, asegurar consistencia entre muestras y procesar cada video para obtener las representaciones numéricas utilizadas por el modelo.

Actividades:

- Limpieza
- Separación por clases
- Extracción y de keypoints

3. **Modelado (25% del tiempo) - $10,125 MXN**

En esta etapa se entrenaron y compararon múltiples arquitecturas (GRU, CNN1D, BiLSTM, MLP, entre otros), hasta seleccionar el MLP simple como modelo final, con métricas destacadas.

Actividades:

- Definición de arquitecturas
- Afinación de hiperparámetros
- Entrenamiento y selección de modelo

4. **Evaluación (20% del tiempo) - $8,100 MXN**

Incluye el cálculo detallado de métricas, generación de matrices de confusión, curvas ROC y Precisión–Recall, análisis de F1 por clase, y reflexión crítica sobre los resultados.

Actividades:

- Análisis cuantitativo
- Elaboración de gráficas
- Interpretación y documentación.

5. **Despliegue (10% del tiempo) - $4,050 MXN**

Aunque en esta fase del proyecto no se realizó un despliegue productivo, sí se diseñó una arquitectura basada en la exposición del modelo como API, el uso potencial de contenedores Docker y la posible integración con Vertex AI + Cloud Run.

Actividades:

- Diseño conceptual
- Compatibilidad del modelo

6. **Monitoreo y mantenimiento (10% del tiempo) - $4,050 MXN**

Se definieron lineamientos para una futura estrategia de:

- Monitoreo de métricas de desempeño en producción
- Incorporación progresiva de nuevos gestos
- Reentrenamiento cuando se acumulen suficientes datos nuevos o se detecte degradación

Almacenamiento en Google Cloud Storage

Tipo de costo	Monto aproximado	Descripción
Almacenamiento puro (50 GB)	$20–30 MXN	Precio directo por espacio en disco
Operaciones y transferencias	$30–60 MXN	Lecturas, escrituras, tráfico interno
Logs y versiones	$10–20 MXN	Registro de accesos y copias
Margen de crecimiento	$40–90 MXN	Reservas para dataset ampliado
Total estimado mensual	**$100–200 MXN**	Escenario realista de uso activo

Inferencia Serverless (Cloud Run)

Tipo de costo	Monto aproximado	Descripción
Ejecución de CPU y memoria	$100–200 MXN	Basado en tarifas de GCP: US$0.000024/vCPU-seg y US$0.0000025/GiB-seg. Un contenedor activo unos 2-3 h/mes con 1 vCPU y 512 MB de RAM genera este rango.
Invocaciones HTTP (requests)	$20–40 MXN	US$0.40 por millón de solicitudes. Con 2,000–5,000 inferencias/mes, se paga una fracción mínima pero se incluye margen.
Tráfico de red / salida de datos	$30–70 MXN	Transferencia hacia usuarios finales o entre servicios. Tarifa típica: US$0.12/GB fuera de la región.
Logs de ejecución (Cloud Logging)	$20–40 MXN	Registros de uso, métricas de latencia y errores. GCP otorga cuota gratuita, pero se asume almacenamiento de logs extendido.
Margen de crecimiento y contingencia	$30–50 MXN	Reserva de 15–25 % para picos de tráfico, cambios en tarifas o escalado automático.
Total estimado mensual	**$200–400 MXN**	Escenario realista y sostenible para una API de inferencia liviana con tráfico moderado.

Mantenimiento y Reentrenamiento

- Actualizaciones semestrales o tras incorporar nuevos gestos.
- Costo estimado: $4,500 MXN por ciclo (~30 h técnicas).
- Monitoreo de métricas y logs: $200–400 MXN

Totales Anuales

Componente	Costo estimado
Desarrollo inicial (único)	$40,500 MXN
Operación anual (≈ $500 × 12 meses)	$6,000
Mantenimiento / reentrenamiento (2 veces al año)	$9,500
Total anual + desarrollo inicial	$56,000

Beneficios

Más allá de los costos, la viabilidad de un sistema de IA se debe evaluar en términos de su impacto.

Beneficios cuantificables

- Un sistema automatizado que clasifica gestos en segundos puede reducir drásticamente el tiempo de trabajo manual requerido en proyectos de investigación, desarrollo de material educativo o prototipos de traducción LSM–español.
- El pipeline diseñado (preprocesamiento con MediaPipe + modelo MLP + diseño de API) puede reutilizarse para más gestos o para otros datasets. Esto disminuye el costo marginal de nuevos desarrollos.
- Con una arquitectura basada en servicios serverless, el costo crece solo si crece el uso, evitando inversiones fijas altas.

Beneficios cualitativos e intangibles

- El proyecto se orienta al reconocimiento de la LSM, contribuyendo a visibilizar una lengua históricamente marginada y explorar tecnologías que pueden reducir barreras de comunicación para comunidades sordas.
- Permite a estudiantes e investigadores aprender IA en un contexto con sentido social, documentar buenas prácticas (CRISP-ML, evaluación crítica, sesgo de datos), construir una base para futuras tesis, artículos y colaboraciones.
- Aunque el proyecto actual es una prueba de concepto con cuatro gestos, sienta las bases para ampliar el vocabulario, trabajar con frases completas e integrar el modelo en aplicaciones reales (traductores, sistemas educativos interactivos).

Riesgos y desafíos de la solución

La implementación de esta solución enfrenta riesgos significativos que podrían impactar su viabilidad, costos y la confianza de los usuarios. Estos desafíos se clasifican en las siguientes categorías:

Riesgos relacionados con los datos

Generalización limitada: Este es el riesgo más crítico identificado en el proyecto. El Análisis Exploratorio de Datos (EDA) reveló que el dataset base (MX-ITESO-100) tiene baja variabilidad (pocos firmantes, condiciones de grabación controladas). Aunque el equipo mitigó esto generando nuevos videos , el alto rendimiento del 97% del modelo MLP se considera influenciado por un entorno que sigue siendo controlado. Existe un alto riesgo de que el modelo falle al enfrentarse a la variabilidad del mundo real (nuevos firmantes, diferentes ángulos de cámara, iluminación variable o fondos complejos).

Sesgo del conjunto de datos: Los datos de entrenamiento actuales, incluso con las adiciones, pueden no ser representativos de toda la diversidad de la Lengua de Señas Mexicana, que incluye variaciones regionales, dialectos o diferencias generacionales. Esto podría resultar en un modelo que funciona bien para un grupo demográfico pero falla para otro, limitando su beneficio social.

Costos de escalabilidad de datos: La solución propuesta depende de la recopilación continua de datos para mejorar. Este proceso no es un costo único, implica gastos recurrentes de recolección, etiquetado, almacenamiento y reentrenamiento, que son cruciales para que la solución pase de ser una prueba de concepto a una herramienta robusta.

Riesgos de Ataques

Envenenamiento de datos (Data Poisoning): La recomendación de crear una aplicación para recopilar más datos del público introduce un vector de ataque. Actores maliciosos podrían enviar datos "basura" o mal etiquetados intencionalmente. Si estos datos se usan para el reentrenamiento, podrían degradar severamente la precisión y confianza del modelo.

Ataques a la API (Abuso y Costos): La arquitectura de despliegue propuesta como una API en serverless (Cloud Run) es vulnerable a ataques de denegación de servicio (DDoS) o abuso de API. Esto no solo interrumpiría el servicio, sino que podría generar costos de operación extremadamente altos e inesperados, impactando directamente el análisis costo-beneficio.

Riesgos de Prueba y Confianza

Exceso de confianza en la métrica: Un "97% de accuracy" suena exitoso, pero el análisis de la solución evidencía que este resultado está influenciado por la baja variabilidad del dataset. Si la solución se implementa y los usuarios experimentan una tasa de error mucho más alta en el uso diario, la confianza en la tecnología bajará drasticamente.

Manejo de gestos fuera de vocabulario (Out-of-Scope): El modelo actual es una prueba de concepto entrenada para solo cuatro gestos específicos. Un desafío crítico es cómo reaccionará el modelo ante cualquier otro gesto de LSM que no esté en su vocabulario.

Ambigüedad y errores críticos: El modelo ya mostró una leve confusión entre "Abrir" y "Avión". A medida que el vocabulario crezca, el riesgo de confusiones entre gestos similares aumentará. Un error de clasificación en un contexto crítico (médico, legal) podría tener consecuencias graves, y la falta de confianza en la precisión del sistema limitaría su adopción.

Riesgos de Cumplimiento

Privacidad y datos biométricos: El proyecto recolecta y procesa videos de personas, lo cual constituye datos biométricos sensibles. Es un riesgo de cumplimiento no gestionar adecuadamente el consentimiento informado de todos los participantes, asegurar el almacenamiento y el manejo anónimo de estos datos conforme a las leyes de protección de datos (como la LFPDPPP en México).

Ética y apropiación cultural: Al trabajar con la LSM , se interactúa con una lengua que es pilar de la identidad de la comunidad sorda. Existe el riesgo de desarrollar una herramienta "sobre" la comunidad, pero sin ella. Si la solución no es validada, aceptada y considerada respetuosa por los usuarios nativos de LSM, o si intenta imponer una "única" forma correcta de señar ignorando variaciones, enfrentará un rechazo ético y social, anulando sus beneficios intangibles.

Bibliografía

1. CloudPrice.net. (2025). Google Cloud Region Pricing (northamerica-south1). CloudPrice.net. Recuperado de https://cloudprice.net/gcp/regions
2. CloudZero. (2024). Understanding GCP Storage Pricing. CloudZero Blog. Recuperado de https://www.cloudzero.com/blog/gcp-storage-pricing/
3. Economize Cloud. (2024). GCP Cloud Run Pricing Guide. Recuperado de https://www.economize.cloud/resources/gcp/pricing/cloud-run/
4. Google Cloud. (2025). Cloud Storage pricing. Google Cloud. Recuperado de https://cloud.google.com/storage/pricing
5. Google Cloud. (2025). Cloud Run pricing. Google Cloud. Recuperado de https://cloud.google.com/run/pricing
6. Google Cloud. (2025). Google Cloud regions: northamerica-south1 (Querétaro, México). Google Cloud. Recuperado de https://cloud.google.com/about/locations
7. MediaPipe Solutions guide. (n.d.). Google AI for Developers. https://ai.google.dev/edge/mediapipe/solutions/guide
8. Martínez-Sánchez, J., Torres, L., & Ramírez, J. (n.d.). MX-ITESO-100: Dataset de gestos de la Lengua de Señas Mexicana (LSM) [Base de datos]. Instituto Tecnológico y de Estudios Superiores de Occidente (ITESO).