Tecnológico de Monterrey | Posgrados

Maestría en Inteligencia Artificial Aplicada (MNA)

Identificación de Gestos en el Lenguaje de Señas Mexicano

Departamento de Computación del Tecnológico de Monterrey Campus Monterrey

Equipo 51

Presentan:

- Carlos Miguel Arvizu Durán – A01410682
- Yohanna Ceballos Salomón – A01795115
- Rubén Díaz García – A01371849

Asesor: María de la Paz Rico Fernández

Patrocinador(es): Raúl Valente Ramírez Velarde

Presentación del Proyecto Integrador

14 de Noviembre del 2025

Problemática: Brecha Comunicativa

- En México existen más de 2.4 millones de personas con discapacidad auditiva (INEGI, 2022).
- La comunicación entre personas sordas y oyentes sigue siendo un desafío estructural, especialmente en contextos educativos y laborales.
- Las soluciones tecnológicas existentes se centran en otras lenguas de señas (como ASL), dejando rezagada la Lengua de Señas Mexicana (LSM).
- La ausencia de herramientas digitales que comprendan gestos dinámicos del LSM genera una brecha que este proyecto busca reducir.

Objetivo General y Alcance

Objetivo Principal
Desarrollar un modelo de aprendizaje profundo capaz de identificar gestos dinámicos del Lenguaje de Manos Mexicano.

Palabras Clave: Abrir, Tú, Avión y Borrar.

Objetivos Específicos

- Implementar una arquitectura eficiente que reconozca secuencias de movimiento.
- Evaluar distintos modelos para determinar el más efectivo.
- Proponer una estrategia de despliegue escalable y adaptable.

El modelo constituye una prueba de concepto funcional con potencial para convertirse en una herramienta inclusiva.

Metodología: CRISP-ML & Trazabilidad

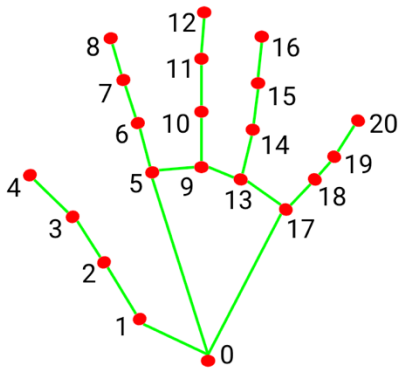
Fase	Actividades Principales
Entendimiento del negocio y datos	Definición del problema de inclusión; revisión de dataset MX-ITESO-100.
Preparación de los datos	Limpieza, segmentación y extracción de keypoints con MediaPipe.
Modelado	Entrenamiento de arquitecturas MLP, CNN1D, GRU y BiLSTM con hiperparámetros ajustados.
Evaluación	Métricas de Accuracy, Recall, F1-score, curvas ROC y análisis de sobreajuste.
Despliegue conceptual	Propuesta de implementación en GCP (Cloud Run, Cloud Storage).
Monitoreo y mantenimiento	Reentrenamiento con nuevos gestos y mayor diversidad de videos.

CRISP-ML aseguró orden, trazabilidad y replicabilidad en todas las fases del proyecto.

Hallazgos e Ideas Clave

MediaPipe: Su uso para la extracción de keypoints fue un éxito. Transformó el problema de análisis de video (muy pesado) a un análisis de series de tiempo (más ligero).

Mediapipe

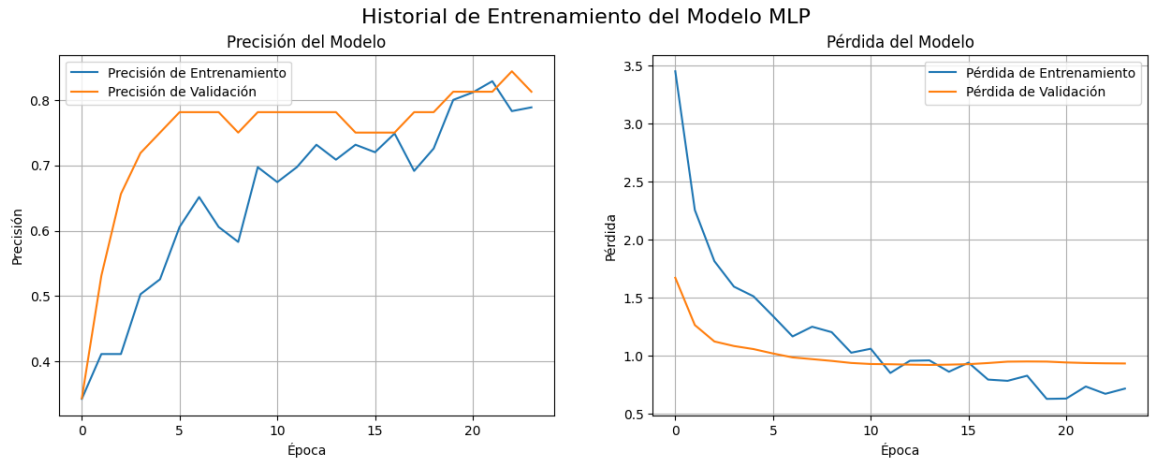


0. WRIST
1. THUMB_CMC
2. THUMB_MCP
3. THUMB_IP
4. THUMB_TIP
5. INDEX_FINGER_MCP
6. INDEX_FINGER_PIP
7. INDEX_FINGER_DIP
8. INDEX_FINGER_TIP
9. MIDDLE_FINGER_MCP
10. MIDDLE_FINGER_PIP
11. MIDDLE_FINGER_DIP
12. MIDDLE_FINGER_TIP
13. RING_FINGER_MCP
14. RING_FINGER_PIP
15. RING_FINGER_DIP
16. RING_FINGER_TIP
17. PINKY_MCP
18. PINKY_PIP
19. PINKY_DIP
20. PINKY_TIP

Hallazgos e Ideas Clave

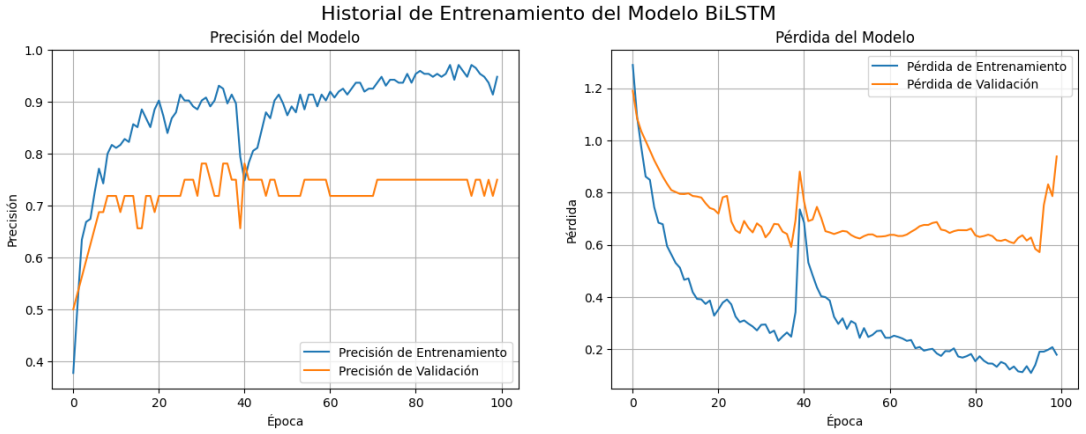
Desempeño de modelos: El modelo más simple, el Perceptrón Multicapa (MLP), obtuvo el mejor rendimiento (97% Accuracy) superando a arquitecturas recurrentes más complejas como GRU y BiLSTM (95% y 89%).

Modelo	Accuracy	Recall	F1-Score	Sobreajuste
MLP	**97%**	**97%**	**97%**	**No**
GRU	95%	95%	95%	Sí
CNN1D	92%	92%	92%	Alto
BiLSTM	89%	89%	90%	Sí



Hallazgos e Ideas Clave

Overfitting como reto principal: Los modelos recurrentes (GRU/BiLSTM) mostraron una clara tendencia al sobreajuste, por otro lado, el MLP no presenta sobreajuste en las gráficas de entrenamiento-validación aunque se refleja una tendencia cuando se incorporan datos muy distintos al dataset.



El Dataset es el factor limitante: El descubrimiento clave es que el rendimiento actual está limitado por la homogeneidad de los datos. Los videos son muy similares (entorno controlado), lo que facilita el trabajo del MLP pero no garantiza que el modelo funcione "en el mundo real" con diferentes personas, ángulos e iluminaciones.

Solución Propuesta: Pipeline

Flujo del sistema:



Solución Propuesta: Pipeline

Ventajas Clave:

- Estructura modular, fácil de adaptar a nuevos gestos.
- Arquitectura ligera y eficiente (MLP).
- Buena presición. (Accuracy)

Interpretación de Resultados y Robustez

- El 97% de accuracy refleja la eficacia del modelo bajo un entorno controlado.
- F1-score y Recall elevados demuestran buena detección incluso en gestos con variaciones leves.
- Sin embargo, los datos presentan similitud entre videos, lo cual puede inducir sesgo.
- Es crítico diversificar las muestras: distintos usuarios, entornos y condiciones de iluminación.

Hacia la Generalización Real

Los resultados son prometedores, pero la expansión del dataset es clave para validar la capacidad de generalización real del modelo en situaciones no controladas.

Recomendaciones comerciales fundamentales

Diversificación de Datos
Se recomienda una alianza estratégica con organizaciones de la comunidad sorda en México para lanzar una campaña de recolección de datos. Esto no solo mejora el modelo, sino que genera confianza, validación ética y adopción temprana.

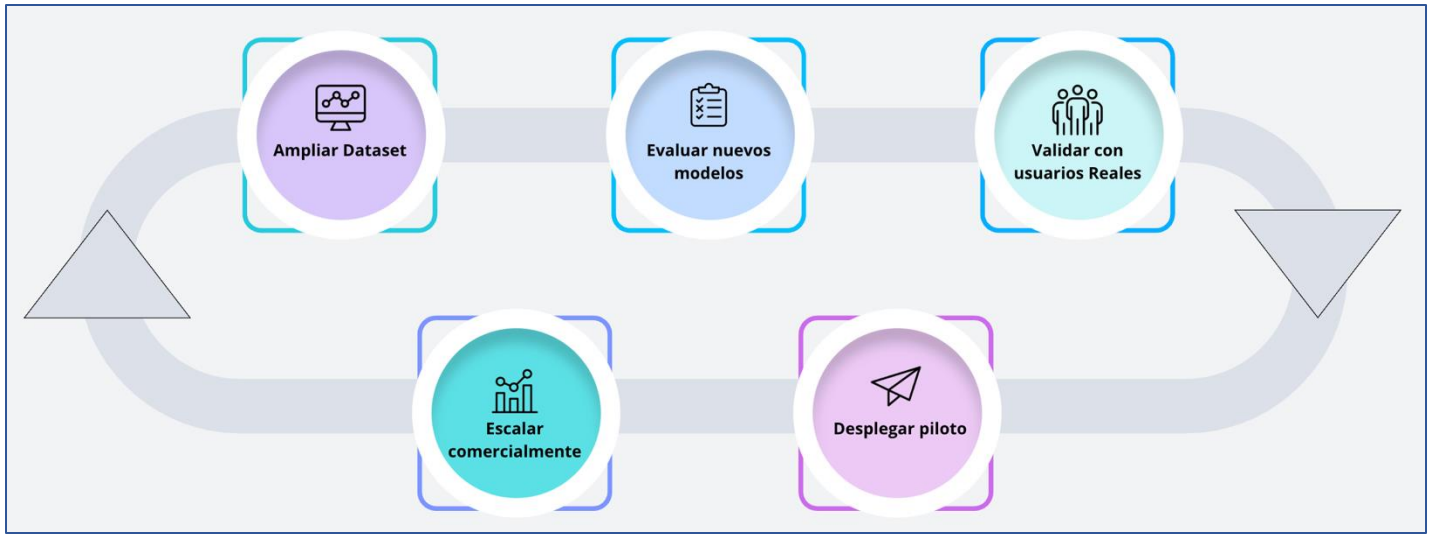
Enfoque en un nicho (MVP)
En lugar de intentar ser un traductor universal inmediato, se recomienda enfocar el producto inicial en un sector de alto impacto como en educación al crear una herramienta interactiva para que personas oyentes aprendan o para que niños sordos refuercen su vocabulario.

Recomendaciones comerciales fundamentales

Potencial de licenciamiento

- API de reconocimiento de señas
- Plataforma de enseñanza personalizada
- Módulo para sistemas de atención al cliente

Mejora iterativa del modelo



Impacto Social y Transformación Digital

Inclusión Comunicativa

Reduce barreras entre comunidades sordas y oyentes.

Educación Digital LSM

Permite enseñar la LSM mediante sistemas interactivos.

Sensibilización Social

Promueve la visibilidad de la comunidad sorda.

Base Tecnológica Nacional

Impulsa investigación local sobre la LSM y IA.

Conclusiones Finales

- El modelo MLP logró un rendimiento sobresaliente (97% accuracy), validando su idoneidad para clasificación dinámica.
- El uso de MediaPipe y un pipeline permitió reducir ruido y mejorar la precisión.
- CRISP-ML aseguró un proceso metodológico transparente y reproducible.

Pasos futuros

- Ampliar el dataset: más gestos, más participantes y variaciones de entorno.
- Arquitecturas avanzadas: evaluar Transformers para secuencias más largas.
- Evaluación ética: buscar la integración de la comunidad sorda para obtener retroalimentación del proyecto.

¡Gracias por su atención!